

Unified TMIL: Một Lượt Truyền Xuôi cho Phát hiện Lừa đảo Ethereum ở Mức Tài khoản và Mức Giao dịch, kèm Benchmark được Kiểm toán và một Nghiên cứu Định vị Trung thực

Bản nộp ẩn danh

Abstract—Chúng tôi nghiên cứu lừa đảo (phishing) trên Ethereum ở hai mức độ chi tiết bằng một mô hình duy nhất: quyết định một tài khoản có phải kẻ lừa đảo hay không (mức tài khoản) và xác định chính xác các giao dịch gian lận bên trong lịch sử của tài khoản đó (mức giao dịch). Thay vì đề xuất một backbone mới, chúng tôi *giữ nguyên* các embedding giao dịch BERT4ETH đã công bố và bộ đọc đầu ra TMIL (temporal multiple-instance-learning), rồi đặt câu hỏi: một sự hợp nhất cẩn thận cùng một giao thức trung thực có thể đi xa đến đâu. Chúng tôi đóng góp ba điều. (i) *Unified TMIL*: một bộ mã hóa dùng chung với hai đầu đọc attention, trong một lượt truyền xuôi tạo ra quyết định mức tài khoản (đầu mềm) và một xếp hạng giao dịch có nhận biết hướng (một đầu được huấn luyện đầu-cuối dưới embedding IN/OUT sẵn có của BERT4ETH thay vì một mặt nạ cứng chỉ-outbound). (ii) Một *benchmark được kiểm toán* xây từ PTXPhish, gồm một *giao thức gán nhãn lại qua hợp đồng* truy vết các biên lai thực thi (transferFrom, Seaport OrderFulfilled) và nâng ground truth mức tài khoản sạch từ 83.4% lên 92.7%, cho ra 292 EOA kẻ lừa đảo đã khử trùng lặp trên ba cơ chế. (iii) Một *đánh giá trung thực*: khoảng tin cậy bootstrap có nhận biết cụm, phân rã âm theo nguồn, phân tầng theo mức hoạt động, và các phép chia ngoài-phân-phối (chéo cơ chế và theo thời gian). Mô hình của chúng tôi đạt AUC chéo miền tổng hợp 0.984 và AUC 0.725 trên các tài khoản lạnh tính DeFi/KOL *khó*, vẫn cạnh tranh với các baseline mạnh (BERT4ETH, ZipZap, TSGN, LMAE4Eth) trong khi là phương pháp duy nhất còn định vị được. Với định vị, chúng tôi báo cáo một kết quả mà lĩnh vực cần nghe: một bộ xếp hạng nhận biết nội dung (content-aware) trên các đặc trưng giá trị/độ mới/vị trí on-chain vượt trội đáng kể so với một prior recency ở Hit@1 (0.832 so với 0.693, paired bootstrap $p=0.002$), nhưng một ablation có kiểm soát cho thấy *bản thân attention học được gần như không đóng góp gì*—loại bỏ nó khiến Hit@1 không đổi (0.802) và MRR còn nhỉnh hơn. Do đó chúng tôi lập luận chống lại việc coi attention là định vị, và công bố benchmark cùng giao thức như một thách thức mở.

I. Giới thiệu

Lừa đảo on-chain rút hàng trăm triệu đô-la mỗi năm. Công trình trước tấn công bài toán hoặc ở mức *tài khoản* (phân loại một địa chỉ) hoặc ở mức *giao dịch*

(gắn cờ một payload), nhưng hiếm khi cả hai bằng một mô hình, và hiếm khi với độ chặt chẽ đánh giá cần thiết để tin tưởng các tập dữ liệu crypto nhỏ và bị tái sử dụng. Mục tiêu của chúng tôi cố tình bị ràng buộc: giữ nguyên backbone BERT4ETH và bộ đọc TMIL, rồi cho thấy một sự hợp nhất cẩn thận cộng với một giao thức trung thực tạo ra một hệ thống tài khoản+giao dịch đáng tin và tái lập được.

Đóng góp.

- **Một kiến trúc hợp nhất thực sự, một-bộ-trọng-số.** Một bộ mã hóa dùng chung nuôi hai đầu attention mà trong một lượt truyền xuôi phân loại tài khoản và xếp hạng các giao dịch của nó (Mục II). Quan trọng là chúng tôi thay *mặt nạ cứng chỉ-outbound* của C-TMIL bằng *embedding IN/OUT* của BERT4ETH, cho mô hình tự học tầm quan trọng của hướng giao dịch thay vì giả định chỉ outbound mới liên quan. Chúng tôi chỉ ra rằng một bộ đọc hậu kỳ là không đủ: đầu định vị phải nhận được gradient trong lúc huấn luyện.
- **Một benchmark được kiểm toán với giao thức gán nhãn lại qua hợp đồng.** Một cuộc kiểm toán khả thi xác lập rằng 83.4% giao dịch PTXPhish có ground truth mức tài khoản sạch một cách trực tiếp; truy vết các biên lai thực thi qua hợp đồng (transferFrom, Seaport OrderFulfilled, ETH nội bộ) nâng con số này lên 92.7%. Chúng tôi khử trùng lặp còn 292 EOA kẻ lừa đảo duy nhất để tránh tái sử dụng mẫu (Mục III).
- **Một giao thức trung thực và một kết quả âm trung thực.** Khoảng tin cậy bootstrap có nhận biết cụm, âm theo nguồn, phân tầng hoạt động, các phép chia OOD, và—quan trọng nhất—một ablation có kiểm soát cho thấy attention học được *không* dẫn dắt việc định vị; các đặc trưng on-chain thủ công và một prior recency mạnh mới làm điều đó (Mục V).

II. Phương pháp

Backbone (không đổi). Mỗi tài khoản là một *túi* (bag) các giao dịch của nó. Theo BERT4ETH, mỗi giao dịch được mã hóa bằng embedding đối tác cùng với hướng IN/OUT, giá trị, đếm và embedding chênh lệch thời gian; chuỗi được ngữ cảnh hóa bởi bộ mã hóa tích chập theo thời gian (TCN) của TMIL. Chúng tôi không thêm bằng embedding mới và không thêm đầu định vị mới.

Xây dựng túi. Chúng tôi dùng một cửa sổ độ dài cố định $L=100$ giao dịch cho mỗi tài khoản. Không gian thiết kế cho phép cửa sổ trượt (W, S); chúng tôi thấy một cửa sổ đơn là đủ vì $>90\%$ EOA kẻ lừa đảo có ít hơn L giao dịch sau mốc neo, và một cửa sổ đơn loại bỏ sự mơ hồ khi tổng hợp điểm mà các cửa sổ chồng lấn gây ra. Với túi dương, cửa sổ kết thúc tại mốc phát hiện (sự kiện phishing được gán nhãn); chúng tôi thảo luận thiên lệch vị trí phát sinh một cách tường minh ở Mục V và trung hòa dạng tâm thường nhất của nó bằng cách loại giao dịch cuối của mỗi túi khỏi cả ứng viên lẫn ground truth cho mọi phương pháp.

Bộ đọc hai đầu. Một đầu gated-attention mềm (Head-C) gộp túi cho mục tiêu BCE mức tài khoản. Một đầu thứ hai (Head-L) xếp hạng giao dịch để định vị. Trong C-TMIL, Head-L che cứng các giao dịch inbound; thay vào đó chúng tôi để embedding IN/OUT sẵn có điều biến attention và huấn luyện Head-L cùng lúc với BCE, để trọng số của nó nhận gradient liên quan đến định vị. Cả hai đầu chia sẻ toàn bộ tham số bộ mã hóa; mô hình huấn luyện một lần và chạy trong một lượt truyền xuôi. Hàm mất mát là $\mathcal{L} = \text{BCE}(\text{Head-C}) + \lambda \text{BCE}(\text{Head-L}) + \beta \mathcal{L}_{\text{contrast}}$.

Vì sao hai đầu. Chúng tôi kiểm chứng bằng thực nghiệm rằng đọc định vị hậu kỳ từ đầu mềm kém hơn một mô hình che được huấn luyện riêng; cho Head-L gradient riêng của nó khôi phục chất lượng định vị trong một bộ trọng số hợp nhất (Bảng VI, các hàng λ). Kiến trúc được trình bày ở Hình 1.

III. Benchmark và Giao thức

Bảng I tóm tắt tập dữ liệu được kiểm toán. **Giao thức gán nhãn lại.** PTXPhish liệt kê một hash giao dịch phishing cho mỗi ca. Với chuyển trực tiếp, hash này là mục tiêu định vị và nằm trong lịch sử tài khoản (83.4% số ca). Với phishing qua hợp đồng (rút Approve/Permit, lắp lệnh Seaport và NFT-order) hash được liệt kê là một phê duyệt phía nạn nhân hoặc một lời gọi sà mà dịch chuyển giá trị xảy ra trong một biên lai thực thi; chúng tôi truy vết transferFrom ERC-20/WETH, Seaport OrderFulfilled và các chuyển ETH nội bộ để quy kết EOA kẻ lừa đảo và gán nhãn lại giao dịch thực thi. Điều này nâng ground truth mức tài khoản sạch lên 92.7% (94.8% nếu loại 108 giao dịch nâng cấp proxy thuộc hạ tầng của kẻ lừa đảo). **Mẫu âm.** Chúng tôi kết hợp các người gửi lành tính PTXPhish *khó* (các tài khoản KOL/DeFi đang hoạt

động) với các EOA Bình thường giữ lại từ BERT4ETH, và luôn báo cáo riêng tập con khó để bể EOA Bình thường gần như tầm thường không thổi phồng các con số tiêu đề. **Phép chia và CI.** Các mẫu dương được khử trùng lặp về các EOA kẻ lừa đảo duy nhất và dùng làm túi kiểm thử zero-shot (mô hình chỉ huấn luyện trên dữ liệu BERT4ETH nội miền, nên không có rò rỉ train/test). Mọi khoảng tin cậy là bootstrap có nhận biết cụm trên các tài khoản độc lập.

IV. Kết quả: Phát hiện mức Tài khoản

Bảng II báo cáo so sánh mức tài khoản với các phương pháp đã công bố và các biến thể gộp MIL, tất cả đều được tái cài đặt trên một bộ mã hóa BERT4ETH dùng chung dưới một giao thức. AUC chéo miền tổng hợp là 0.984; trên tập con khó là 0.725 (95% CI [0.658, 0.791]). Chúng tôi minh bạch về điều này: gộp trung bình đơn giản và BERT4ETH ngang bằng hoặc vượt chúng tôi về AUC âm-khó, nên đóng góp mức tài khoản của chúng tôi là sự *hợp nhất*—chúng tôi là mục duy nhất còn định vị được—chứ không phải một state-of-the-art mức tài khoản mới. Bảng III phân tầng theo mức hoạt động: AUC vẫn cao trên ngẫu nhiên ngay cả ở tầng 100+ giao dịch, nên tín hiệu không phải chỉ là tạo tác “người-dùng-cường-độ-cao so với tài-khoản-ngắn-ngày”. Bảng VII cho thấy AUC mức tài khoản duy trì trên mọi phân vùng OOD chéo cơ chế và theo thời gian.

V. Kết quả: Định vị mức Giao dịch

Bảng IV báo cáo định vị sau khi loại bỏ tạo tác mốc-phát-hiện (giao dịch cuối của mọi túi tầm thường là GT và bị loại cho mọi phương pháp). Ba phát hiện nổi bật, và phát hiện thứ ba là quan trọng nhất.

(1) Xếp hạng nhận biết nội dung vượt heuristic và recency ở Hit@1. Bộ xếp hạng nhận biết nội dung của chúng tôi—một hợp nhất gradient-boosted của các đặc trưng on-chain (đỉnh số tiền so với max chạy, độ mới, vị trí, outbound giá trị không, tần suất đối tác, và một “đanh tiếng rút tiền” của đối tác theo leave-one-bag-out có kiểm soát rò rỉ)—đạt Hit@1 0.832, đáng kể trên prior recency 0.693 ($\Delta=+0.128$, paired bootstrap $p=0.002$, CI [0.040, 0.238] loại trừ 0). Do đó nó xác định *chính xác* biên lai phishing thường xuyên hơn, trong khi ngang bằng recency ở Hit@5/10 thô hơn.

(2) Recency là một baseline mạnh, trung thực. Vì các cửa sổ dương kết thúc tại mốc phát hiện, các biên lai phishing dồn về cuối lịch sử kẻ lừa đảo, nên một prior recency thuần đã đạt Hit@5/10 quanh 0.92–0.93. Mọi tuyên bố định vị phải được đo so với prior này; chúng tôi báo cáo nó nổi bật thay vì giấu đi.

(3) Attention học được gần như không đóng góp gì. Bảng V tách biệt giá trị biên của attention dưới giao thức y hệt. Loại đặc trưng attention khỏi bộ xếp hạng nhận biết nội dung khiến Hit@1 không đổi (0.802) và *nâng* MRR (0.854→0.861); bộ xếp hạng chỉ-attention

(0.416 Hit@1) thấp xa recency. Nói cách khác, tín hiệu định vị nằm trong các đặc trưng on-chain thủ công, không phải trong trọng số attention của mô hình. Điều này nhất quán với mảng tài liệu rộng hơn nghi ngờ attention như lời giải thích [9], và chúng tôi nói thẳng: ở đây *attention không phải là định vị*. Chúng tôi định khung định vị giao dịch như sàng lọc được trợ-giúp-xếp-hạng, dẫn-dắt-bởi-đặc-trưng, và công bố nó như một thách thức benchmark mở.

VI. Các Ablation

Bảng VI ablate các thành phần backbone (không đổi) cho chuyển giao mức tài khoản. Loại embedding đối tác gây hại nhất (AUC âm-khó 0.849→0.461); loại embedding hướng IN/OUT là động lực chính của suy giảm chuyển giao trên mẫu âm khó (0.849→0.662), biến minh bằng thực nghiệm cho lựa chọn thay mặt nạ cứng chỉ-outbound bằng embedding IN/OUT học được. Các hàng λ xác nhận rằng huấn luyện đồng thời Head-L ($\lambda > 0$) không làm hại hiệu năng mức tài khoản.

VII. Thảo luận và Hạn chế

Chúng tôi phơi bày, chứ không giấu, các điểm yếu. **Bể mẫu âm khó nhỏ.** Tập con khó chỉ gồm 80 tài khoản DeFi/KOL; AUC của nó mang phương sai giữa các lần chạy không nhỏ, nên chúng tôi báo cáo CI có nhận biết cụm và xử lý ước lượng điểm một cách thận trọng. Chúng tôi giữ nguyên PTXPhish để so sánh được thay vì thổi phồng bằng mẫu âm dễ. **Thiên lệch vị trí.** Neo các cửa sổ dương tại mốc phát hiện khiến recency thành một prior mạnh; chúng tôi trung hòa ca giao-dịch-cuối tầm thường và đo mọi phương pháp so với recency. **Attention không trung thực cho định vị,** như ablation của chúng tôi cho thấy; do đó chúng tôi không đưa ra tuyên bố giải thích nào cho trọng số attention. **Độ phủ.** Ground truth định vị sạch phủ 92.7% PTXPhish; các giao dịch hạ tầng nâng cấp proxy còn lại để dành cho truy vết tương lai. Mô hình mức tài khoản của chúng tôi cạnh tranh nhưng không vượt trội tuyệt đối, theo thiết kế: đóng góp là sự hợp nhất, một benchmark sạch và một giao thức trung thực.

VIII. Kết luận

Unified TMIL thực hiện phát hiện lừa đảo Ethereum ở mức tài khoản và mức giao dịch trong một lượt truyền xuôi trong khi giữ nguyên backbone BERT4ETH và TMIL. Thay mặt nạ cứng chỉ-outbound bằng embedding IN/OUT học được là thay đổi cốt yếu mở đường. Phát hiện tiêu đề của chúng tôi cho cộng đồng mang tính cảnh báo: các prior vị trí mạnh và các đặc trưng on-chain thủ công—không phải attention—mới dẫn dắt định vị giao dịch hiện nay. Chúng tôi công bố benchmark được kiểm toán, giao thức gán nhãn lại qua hợp đồng, các baseline, và mã đánh giá để xúc tác tiến bộ chặt chẽ.




Fig. 1. Unified TMIL. Một bộ mã hóa dùng chung (embedding đối-tác/IN-OUT/số-tiền/dếm/thời-gian → TCN) nuôi hai đầu attention trong một lượt truyền xuôi: một đầu mềm (Head-C) gộp túi để phân loại tài khoản, và Head-L—dùng embedding IN/OUT của BERT4ETH thay cho mặt nạ cứng chỉ-outbound, huấn luyện đồng thời dưới BCE—xếp hạng các giao dịch.




Fig. 2. AUC mức tài khoản chéo miền zero-shot theo nguồn mẫu âm: PTXPhish lành tính khó (KOL/DeFi) so với EOA Bình thường so với tổng hợp.

References

- [1] M. Ilse, J. Tomczak, and M. Welling, “Attention-based deep multiple instance learning,” in *ICML*, 2018.
- [2] S. Hu et al., “BERT4ETH: A pre-trained transformer for Ethereum fraud detection,” in *WWW*, 2023.
- [3] BlockSec, “PTXPhish: payload-based transaction phishing detection on Ethereum,” 2023.
- [4] J. Liu et al., “ZipZap: efficient training of language models for Ethereum fraud detection,” in *WWW*, 2024.




Fig. 3. Định vị. (a) Các bộ xếp hạng ở Hit@1/5/10: hợp nhất nhận biết nội dung vượt recency ở Hit@1 ($p=0.002$). (b) Ablation đóng góp attention: loại attention học được khỏi bộ xếp hạng nhận biết nội dung không gây hại (Hit@1 không đổi, MRR nhỉnh lên), tức attention không phải nguồn của tín hiệu.




Fig. 4. AUC mức tài khoản ngoài-phân-phối trên các phép chia chéo cơ chế (giữ lại một loại) và theo thời gian.

- [5] J. Wang et al., “TSGN: transaction subgraph networks for identifying Ethereum phishing accounts,” 2022.
- [6] “LMAE4Eth: masked auto-encoding with language-model embeddings for Ethereum account analysis,” 2024.
- [7] Z. Shao et al., “TransMIL: transformer based correlated multiple instance learning for whole slide image classification,” in *NeurIPS*, 2021.
- [8] M. Y. Lu et al., “Data-efficient and weakly supervised computational pathology on whole-slide images,” *Nature Biomedical Engineering*, 2021.
- [9] S. Jain and B. Wallace, “Attention is not explanation,” in *NAACL*, 2019.

TABLE I

Tập dữ liệu được kiểm toán. GT chuyển-trực-tiếp phủ 83.4%; giao thức gán nhãn lại qua hợp đồng (truy vết mức biên lai transferFrom/Seaport/NFT-order) nâng GT mức tài khoản sạch lên 92.7% (94.8% nếu loại các giao dịch nâng cấp proxy hạ tầng của kẻ lừa đảo). Mẫu dương là các EOA kẻ lừa đảo duy nhất; mẫu âm kết hợp PTXPhish lành tính khó (KOL/DeFi) và các EOA Bình thường giữ lại.

Tập con	Số lượng
Giao dịch phishing đã kiểm toán (PTXPhish)	4998
GT sạch chuyển-trực-tiếp	4168 (83.4%)
+truy-vết-biên-lai (Seaport/NFT/transferFrom)	+466
tổng GT mức tài khoản sạch	4634 (92.7%)
EOA kẻ lừa đảo duy nhất (mẫu dương)	292
poisoning / payable / ice_phishing	188 / 59 / 45
Mẫu âm khó (PTXPhish lành tính, KOL/DeFi)	80
Mẫu âm EOA Bình thường giữ lại	1324
Túi định vị GT-nội-vùng	101

TABLE II

So sánh mức tài khoản với SOTA đã công bố và các baseline gộp MIL, tất cả tải cài đặt trên một bộ mã hóa BERT4ETH dùng chung dưới một giao thức. ID = nội miền; X = chéo miền zero-shot PTXPhish; X_{kh} = AUC chỉ với các người gửi lành tính PTXPhish khó. Mô hình chúng tôi cạnh tranh *trong khi còn định vị được*, điều không baseline nào làm.

Phương pháp	ID-F1	ID-AUC	X-AUC	X-AUC _{kh}
<i>Phương pháp mức tài khoản đã công bố (tải cài đặt)</i>				
BERT4ETH [2]	0.734	0.925	0.989	0.836
ZipZap [4]	0.711	0.915	0.979	0.776
TSGN [5]	0.727	0.918	0.985	0.760
LMAE4Eth [6]	0.750	0.933	0.980	0.708
<i>Baseline gộp MIL (bộ mã hóa dùng chung)</i>				
Max-pool MIL	0.752	0.933	0.978	0.779
Gated-attn MIL [1]	0.733	0.922	0.965	0.803
Mean-pool MIL	0.755	0.933	0.957	0.885
Unified TMIL (của chúng tôi)	0.743	0.922	0.984	0.725

TABLE III

AUC mức tài khoản phân tầng theo mức hoạt động (#tx). AUC cao duy trì ngay cả ở tầng hoạt-động-cao.

Tầng (#tx)	#âm	#dương	AUC
3-20	1218	54	0.999
20-100	104	103	0.971
100+	76	130	0.741

TABLE IV

Định vị giao dịch trên PTXPhish ($n=101$), đã loại tạo tác mồi-phát-hiện; 95% CI bootstrap cụm trong ngoặc. Các prior heuristic và baseline MIL (Gated-attn [1], TransMIL [7], CLAM [8]) dùng cùng bộ mã hóa và giao thức. Hợp nhất nhận biết nội dung **vượt đáng kể** recency ở Hit@1 ($p=0.002$). [†]cải thiện đáng kể so với recency.

Bộ xếp hạng	Hit@1	Hit@5	Hit@10	MRR
<i>Prior heuristic</i>				
Amount-rank	0.347	0.584	0.663	0.447
Degree-rank	0.465	0.772	0.822	0.607
Novelty-rank	0.356	0.782	0.832	0.551
Recency-rank	0.693	0.921	0.931	0.799
<i>Baseline MIL (bộ mã hóa dùng chung)</i>				
Gated-attn MIL [1]	0.446	0.752	0.881	0.598
TransMIL [7]	0.406	0.673	0.792	0.533
CLAM [8]	0.455	0.792	0.871	0.599
<i>Học / hợp nhất (của chúng tôi)</i>				
Head-L chỉ-attention	0.416	0.752	0.891	0.576
Hợp nhất nhận biết nội dung[†]	0.832	0.931	0.941	0.880
	[.752,.901]	[.881,.980]	[.891,.980]	[.823,.932]

TABLE V

Ablation đóng góp attention (bộ xếp hạng nhận biết nội dung, không-danh-tiếng, cùng giao thức LOO, $n=101$). Loại đặc trưng attention học được *không* gây hại: Hit@1 không đổi và MRR nhỉnh hơn. Tín hiệu định vị đến từ các đặc trưng on-chain thủ công, không phải attention.

Biến thể	Hit@1	Hit@5	Hit@10	MRR
Nhận biết nội dung (+attn)	0.802	0.921	0.950	0.854
Nhận biết nội dung (−attn)	0.802	0.931	0.960	0.861
Prior recency	0.693	0.921	0.931	0.799
Chỉ attention	0.416	0.752	0.891	0.576

TABLE VI

Ablation backbone (2 seed), chuyển giao mức tài khoản. Embedding đối tác và IN/OUT dẫn dắt chuyển giao âm-khó; huấn luyện đồng thời Head-L ($\lambda>0$) không gây hại hiệu năng mức tài khoản.

Biến thể	ID-F1	X-AUC	X-AUC _{kh}
Mô hình đầy đủ	0.734	0.974	0.849
– bộ mã hóa TCN	0.735	0.955	0.592
– embedding đối tác	0.554	0.960	0.461
– embedding IN/OUT	0.717	0.928	0.662
$\lambda=0$ (chỉ mềm)	0.733	0.965	0.803
$\lambda=0.25$	0.735	0.969	0.837

TABLE VII

Khái quát hóa mức tài khoản ngoài-phân-phối. Các phân vùng chéo cơ chế giữ lại trộn một cơ chế phishing; các phép chia theo thời gian huấn luyện/kiểm thử qua mốc thời gian trung vị.

Phân vùng OOD	#đương	AUC	AUPR
<i>Chéo cơ chế (giữ lại một loại)</i>			
payable_function	59	0.998	0.894
ice_phishing	45	0.967	0.316
address_poisoning	188	0.984	0.765
<i>Theo thời gian</i>			
sớm (train)	146	0.985	0.802
muộn (test)	146	0.983	0.763